


הצעת פרויקט



SMART SERVICE

CHAT

סמל מוסד: 340695.

שם המכללה: סמינר בית יעקב, רכסים.

שם הסטודנט: תמר מוריאל.

ת.ז. סטודנט: 215131129.

שם הפרויקט: SmartService Chat.

תיאור הפרויקט

בפרויקט זה תפוח מערכת צ'אט חכמה למוקד שירות לקוחות, המשלבת עיבוד שפה טבעית (NLP) וניתוח נתונים לצורך מתן מענה מדויק, מהיר ואישי לקוחות.

נועדה לעזור לחברות ולמוקדי שירות יעילה עם הלקוחות שלהם, לזהות את צרכי הלקוח בזמן אמת, ולשפר את חווית השירות.

בכניסה למערכת המערכת דורש סיסמה לזיהוי המשתמש במידה והמשתמש חדש הוא יצטרך לבצע רישום עם פרטים אישיים ורק לאחר מכן יוכל להיעזר בשירותינו.

המערכת מקליטה/מקבלת-טקסט ומנתחת את צד הלקוח, (בעת הקלטה המערכת ממירה את השמע לטקסט) המערכת אוספת מידע על הלקוח, בעת חוסר מידע על השאלה/לקוח וכולי המערכת שואלת את הלקוח שאלות ממוקדות, המערכת מנתח את השאלה, שואבת את התשובה מבין האתרים, המערכת מטפלת אף בתלונות וכן בכעס/בלבול, (כאשר צד הלקוח היה על ידי תקשור עם הקלטה – המערכת תמיר את הטקסט של התשובה לשמע), בסיום השיחה המערכת מספקת דוחות וסיכום על השיחה עם תובנות מסקנות תמלול ועוד....

ייעוד המערכת היא לשפר את איכות השירות, הדיוק והיעילות של מוקדי השירות על ידי שימוש בבינה מלאכותית לניתוח קולי ולסנטימנט.

מטרת המערכת:

- לספק פתרון מתקדם המשלב בינה מלאכותית, ניתוח טקסטים ונתונים, וזיהוי משתמשים – על מנת לשפר את שירות הלקוחות.
- לחסוך זמן עבודה לנציגים.
- ליצור חווית לקוח חכמה ואישית, זמינות והגעה לשרותי לקוחות רבים בצאט אחד.
- לנהל היסטוריית שיחות לכל לקוח לצורך שיפור השירות בהמשך. מחיקת נתונים ישנים/מיותרים.

הגדרות קלט פלט:

קלט:

- סיסמת משתמש.
- הקלטת הלקוח או טקסט על פי החלטת הלקוח. בזמן אמת.
- התבססות על דוחות סיכום מהשיחות קודמות עם הלקוח. מה הרגיע אותו וכולי...

פלט:

- מענה לשאלת הלקוח או שאלת מיקוד להבנה עמוקה יותר של הנושא. בשמע או בטקסט – על פי צד הלקוח.
- דוחות סיכום שיחה הכוללים תמלול, סנטימנט, הצעות לשיפור, מדדי ביצועים וניקוד למוקדן.
- בזמן פתיחת שיחה חדשה, מזהה האם מדובר בלקוח חדש או לקוח קיים, בודקת אם הנושא קשור לפניות קודמות, וכן עוסק בניקוי רעשי רקע מהשמע.

שלבי הפיתוח:

1. בעת קליטת הנתונים (שמע – ממירה לטקסט/טקסט) המערכת בודקת אם המשתמש הוא לקוח חדש או קיים. בעת הצורך בקשת פרטים נוספים מהלקוח לצורך זיהויו.
2. הבנת משמעות ההודעה: זיהוי הכוונה של הלקוח, סיווג הפנייה לפי נושא, וזיהוי האם השיחה היא המשך לפנייה קודמת או שיחה חדשה לחלוטין.
3. אם חסרים נתונים חשובים לצורך הבנת מכלול הבקשה – המערכת שואלת שאלות ממוקדות כדי להשלים את התמונה ולבנות פרופיל מלא לשאלה.
4. המערכת בודקת אם הלקוח מרוצה, מתוסכל, לחוץ או כועס, לפי טון דיבור ומילים רגשיות. לפי התוצאה היא משנה את אופי התגובה (על פי הסטורית שיחות) או מזהה שמדובר בתלונה

- ומגיבה בהתאם. כאשר מזוהה תלונה – המערכת מסכמת את הבעיה, מחפשת גורם אפשרי לתקלה, ומציעה פתרון, פיצוי ובעת הצורך הפנייה למנהל שירות.
5. שליפה המידע ממסד נתונים, מאגר ידע פנימי או מאתרי מידע. בשלב זה המערכת מנתחת את הנתונים ובוחרת את הפתרון המתאים ביותר.
 6. ניסוח תשובה טבעית בהתאם לסגנון השיחה, למצב הרגשי של הלקוח, ולפתרון שנבחר. המערכת דואגת לדיוק, בהירות ונימוס.
 7. דוח אוטומטי הכולל: מידע על הלקוח, תמלול שיחה, נושא הפנייה, רמת שביעות הרצון, רגשות שזוהו וצורת טיפול. עם הזמן, המערכת לומדת אילו ביטויים, טונים ותגובות מרגיעים את הלקוחות בצורה היעילה ביותר, בונים אמון ופותרים בעיות - והופכים נתונים אמיתיים להמלצות לשיטות עבודה מומלצות להדרכה ואוטומציה. שמירת הדוח ביומן לקוח.
 8. ניהול ההיסטוריה: המערכת שומרת את סיכומי השיחות הקודמות לכל לקוח, מוחקת נתונים לא רלוונטיים או ישנים, וכן מעדכנת המלצות והנחיות בהתבסס על היסטוריית השיחות. במידה והלקוח חדש המערכת יוצרת משתמש חדש ושומרת את הדוח תחת שמו.

סיכום פעילות המערכת:

המערכת מכילה שני משתמשים:

- User-1:** משתמשי הצאט. בכניסה לצאט מקישים קוד משתמש. אם הוא משתמש חדש יהיה עליו להירשם ורק לאחר מכן יוכל להיכנס בכדי להשתמש בשירותינו. על המשתמש לבחור באיזה נושא יהיה מתן השירות. וכעת המשתמש יכול לכתוב/להקליט את בקשתו, הצאט יחזיר אליו את התשובה. משתמש זה יוכל לצפות בהיסטוריית שיחותיו בלבד.
- User-2:** מנהל המערכת. מכניס את סיסמתו. המערכת מזהה שמשתמש זה הינו המנהל ומאפשרת לו להגיע למקומות נוספים. יש למנהל הרשאת גישה לקוד של המערכת החכמה כולה לתקלה או עידכון. ליומן לקוח - הכולל סיכומי שיחה.

הבעיות האלגוריתמיות

SmartService Chat הוא צ'אט חכם המנתח בזמן אמת את ההודעות של המשתמש, מזהה רגשות ותגובות, ומספק מענה מותאם אישית. המערכת משלבת עיבוד שפה טבעית ולמידת מכונה כדי לשפר את האינטראקציה ולהפוך את השיחה ליעילה ומדויקת יותר.

פעמים רבות אנו נפגשים במקרים שבהם לקוח קיבל מידע שגוי/לא מדויק/חסר סעיף מהאיש השרות, וכן מקרים בהם הלקוח התעצבן/דיבר שיח חרשים/התבלבל ממלל המוקדן ונגרם ללקוח ולעיתים אף למוקדן עוגמת נפש מרובה.

ועל כן ניצור את המערכת שתפתור בעיות אלו על ידי צ'אט שירות לקוחות המכיל בתוכו תחומים רבים. הלקוח יקבל את מרב השירות, הזמינות, המהירות, הדיוק, האמינות, באופן אובייקטיבי, והכל במקום אחד זמין ונוח.

הבעיה העיקרית בפרויקט היא ניתוח טקסט.

שלב א. המרת שמע לטקסט:

- כדי שנוכל לנתח את השיחה להגיע לדיוק מירבי, המערכת ממירה את השיחה לטקסט.

שלב ב. בכניסה למערכת זיהוי משתמש:

- על מנת שהמערכת תוכל לתת שירות מותאם אישית לאדם, על המערכת לזהות את האדם וזאת על ידי הקשת סיסמה.
- במקרה של משתמש חדש: בעת רישום לצאט על הלקוח לתת את פרטיו. במקרה שחסר פרטים המערכת תבקש ממנו באופן ממוקד אלו נתונים חסר לה לצורך שמירתו כמשתמש. בסיום הרישום המערכת תשלח למשתמש סיסמה שעל פיה יוכל להיכנס למערכת.

שלב ג. בדיקה האם השיחה שיחת המשך:

- לעיתים הלקוח רוצה להמשיך את השיחה הקודמת או להתבסס על הנתונים מהשיחה האחרונה, ועל כן על המערכת לבדוק האם שיחה זו שיחת המשך או בהתבססות על הנתונים הקודמים.

שלב ד. הבנת משמעות ההודעה:

- על המערכת לבצע על הטקסט ניקוי רעשי רקע כדי שנוכל להתמקד במילים המשמעותיות.
- זיהוי בקשת הלקוח למטרת מענה מתאים.
- הטקסט צריך להיות מובנה ומחולק לפי נושאים כדי שניתן יהיה לנתח את כל חלקי השיחה ולתת מענה מקיף ומדויק ככל האפשר.
- במקרה והלקוח לא נתן מספיק נתונים על בקשתו המערכת תשאל אותו שאלות ממוקדות על הפרטים החסרים להבנת המכלול.

שלב ה. זיהוי תלונה:

- המערכת צריכה לזהות את מצב רוחו של הלקוח: האם הוא כועס, מבולבל, מתעצבן, מרוצה או ניטרלי. זיהוי רגשות דורש גם אלגוריתמים לזיהוי דפוסי דיבור, הטונים, והשפה, ולא רק תמלול מילולי.
- כאשר המערכת מזהה אינטונציה תלונתית - על ידי טון דיבור, מילים המשמשות תלונה וכיוצא בזה המערכת תטפל במקרה כתלונה.

שלב ו. טיפול בתלונה:

- שליפת נתונים מהיסטוריית השיחות - מה הרגיע את הלקוח...
- סיכום בעיית התלונה.
- חיפוש גורם אפשרי לתקלה.
- הצעת פתרון/פיצוי.
- בעת הצורך הפנייה למנהל שירות.

שלב ז. שליפת מידע ממסד הנתונים:

- ניתוח הנתונים לצורך מענה נכון ומתאים ביותר.
- בכדי שהמערכת תוכל לענות ללקוח על שאלותיו עליה לשאוב מידע מאתר או ממסד נתונים הקשור לבקשתו.
- בחירת התשובה המתאימה ביותר לבקשה מתוך האתר/מסד נתונים.

שלב ח. ניסוח התשובה:

- בכדי שהלקוח יקבל תשובה מובנת, ברורה, מתאימה וכולי על המערכת לנסח תשובה טבעית בהתאם לסגנון השיחה, למצב הרגשי של הלקוח, ולפתרון שנבחר.
- אם הקלט שהתקבל מהלקוח הוא שמע על המערכת להפוך את התשובה שניסחה ואספה לשמע. וזאת ליצירת שרות הטוב ביותר.

שלב ט. יצירת דוח אוטומטי:

- מטרת המערכת לתת את השירות המקסימלי מותאם לכל אדם על פי אופיו ולחסוך מקרים שבהם השיחה מגיעה למחוזות לא נעימים בשל חוסר הבנה, עלות מחירים... ולכן בכדי שהמערכת תוכל לשפר את השירות במהלך שיחה המערכת יוצרת דף סיכום השיחה הכולל: תמלול השיחה, סנטימנט ורגשות של הלקוח שזוהו. במקרה של כעס - מה הרגיע אותו, הצעות לשיפור. ושומר את הסיכום ביומן לקוחות.
- לאורך זמן, המערכת צריכה ללמוד אלו ביטויים, טונים ותגובות מרגיעים את הלקוחות בצורה המיטבית.

שלב י. שמירת נתונים:

- בסיום השיחה המערכת שומרת את סיכום השיחה ביומן לקוח.

שלב יא. ניהול ההיסטוריה:

- המערכת שומרת לכל לקוח בנפרד את סיכומי השיחות הקודמות. על המערכת לנהל את ההיסטוריה של הסיכומים. מחיקת נתונים לא רלוונטיים עבור כל לקוח, לדוגמא: נתונים ישנים. בעת מחיקת לקוח המערכת מוחקת את כל ההיסטוריה של לקוח זה. בעת זיכרון נתונים מלא, המערכת מרעננת את הזיכרון ומוחקת נתונים שדחופים פחות או מתריעה על מרכז זיכרון חדש.

רקע תאורטי

בעשור האחרון חלה עלייה משמעותית בשימוש במערכות צ'אט ובמוקדי שירות לקוחות דיגיטליים. רוב המערכות שהיו בשימוש בעבר פעלו על בסיס כללים קבועים מראש (Rule-Based Systems) או השתמשו בתבניות תשובה פשוטות, ללא יכולת להבין באמת את כוונת המשתמש או את מצבו הרגשי. תוצאה זו יצרה פעמים רבות שיח לא טבעי, מגושם ולעיתים מתסכל עבור המשתמש.

במקביל, מוקדי שירות הלקוחות סבלו מעומסים כבדים, זמני המתנה ארוכים וחוסר עקביות במתן מענה. נציגי שירות נדרשו להתמודד עם מגוון רחב של פניות בו-זמנית, ללא כלי עזר שיכולים לסייע להם להבין בזמן אמת את רמת שביעות הרצון של הלקוח, את רמת הדחיפות של הפנייה או את רמת הבלבול והמתח שמורגשים בשיחה. כך נוצר פער משמעותי בין הצורך של הלקוחות בחוויית שירות אישית, מהירה ומדויקת — לבין היכולת של מערכות השירות הקיימות לספק מענה זה.

בנוסף, מערכות צ'אט קיימות כמעט ולא כללו יכולות ניתוח רגשי. הן לא היו מסוגלות לזהות האם המשתמש כועס, מתוסכל, רגוע או מבולבל. היעדר הבנה זו מנע מהמערכת להגיב באופן מותאם אישית, לאפשר ניהול שיחה אנושי יותר ולזהות מצבים שבהם הלקוח זקוק להכוונה נוספת. במוקדי שירות, המשמעות הייתה חוסר ביכולת לזהות בזמן אמת שיחה שמתדרדרת, לקוח שמאבד סבלנות או פנייה שמצריכה התערבות מהירה של נציג בכיר.

SmartService Chat פותחת דלת לדור חדש של מערכות תקשורת. היא משלבת טכנולוגיות מתקדמות של עיבוד שפה טבעית (NLP), למידת מכונה וחיזוי רגשות, ומאפשרת ליצור אינטראקציה חכמה ומשמעותית יותר.

היתרונות העיקריים של המערכת הם:

- **הבנת טקסט עמוקה:** המערכת יודעת לזהות כוונות, הקשרים ומשמעויות נסתרים שלא ניתן להגיע אליהם באמצעות חוקים פשוטים.
 - **זיהוי רגשות בזמן אמת:** מאפשר להבין את מצב המשתמש, לזהות מתחים או תסכול, ולהתאים את התגובה בהתאם למצבו.
 - **שיפור מוקדי שירות:** נציגים מקבלים תמונת מצב על רמת שביעות הרצון של הלקוח, יכולים לתעדף פניות בעייתיות ולייעל את השירות.
 - **תגובה דינמית בהתאמה אישית:** המערכת אינה מסתמכת על תבניות קשיחות אלא מתאימה כל תגובה לתוכן ולמצב הרגשי של השיח.
 - **שיפור חוויית השימוש:** השיחה מרגישה טבעית יותר, רציפה וידידותית, מה שמעלה את שביעות רצון המשתמשים ומפחית עומסים על הנציגים.
- באופן זה, SmartService Chat מציעה פתרון כולל שמטפל גם בבעיות של מערכות הצ'אט המסורתיות וגם באתגרים של מוקדי שירות לקוחות — ומייצרת חוויית תקשורת חכמה, יעילה ומותאמת אישית.

פיתוחים הקיימים כיום:

1. הפיכת שמע לטקסט - כשהקלט שמע:
 - **Connectionist Temporal Classification (CTC) Algorithm** : משמש לאימון מערכות זיהוי דיבור להמיר קלט שמע לטקסט, גם אם אורך הקלטת השמע אינו תואם בצורה מושלמת את אורך התמליל הכתוב.
 - **Hidden Markov Models (HMMs)** : מודלים סטטיסטיים של מרקוב בהמרת דיבור לטקסט הם מודלים סטטיסטיים המסייעים לקבוע את רצף המילים והתווים הסביר ביותר על סמך צלילים מדגימת שמע.
 - **Whisper ASR** : היא מערכת זיהוי דיבור בקוד פתוח מבית OpenAI, שאומנה על בסיס מערך נתונים גדול ומגוון של 680,000 שעות של נתונים רב-לשוניים וריבוי משימות שנאספו מהאינטרנט. Whisper יכולה לתמלל דיבור באנגלית ובמספר שפות אחרות, ויכולה גם לתרגם ישירות ממספר שפות שאינן אנגלית לאנגלית.

- **DeepSpeech** : היא מערכת זיהוי דיבור בקוד פתוח שפותחה על ידי מוזילה בשנת 2017 ומבוססת על אלגוריתם הומונימי של באידו.
- **Wav2vec** : מתוצרת הענקית Meta, היא ערכת כלים לזיהוי דיבור המתמחה באימון עם נתונים לא מותיגים, בניסיון לכסות כמה שיותר ממרחב השפות המכסה שפות המיוצגות בצורה גרועה במערכי הנתונים המבוארים המשמשים בדרך כלל לאימון בפיקוח.
- **Kaldi** : היא ערכת כלים לזיהוי דיבור שנכתבה ב-C++, שנולדה מתוך הרעיון של קוד מודרני וגמיש שקל לשנות ולהרחיב. חשוב לציין, ערכת הכלים של Kaldi מנסה לספק את האלגוריתמים שלה בצורה הגנרית והמודולרית ביותר האפשרית, כדי למקסם את הגמישות והשימוש החוזר (אפילו לקוד מבוסס בינה מלאכותית אחר מחוץ לתחום פעילותה של Kaldi).
- **SpeechBrain** : היא ערכת כלים "הכל באחד" לדיבור. משמעות הדבר היא שהיא לא רק מבצעת ASR, אלא את כל מערך המשימות הקשורות לבינה מלאכותית שיחתית: זיהוי דיבור, סינתזת דיבור, מודלים של שפה גדולה ואלמנטים אחרים הנדרשים לאינטראקציה טבעית מבוססת דיבור עם מחשב או צ'אטבוט.
- **Sonix** : המרה מדויקת של דיבור לטקסט ביותר מ-53 שפות. עורך הדפדפן של Sonix מאפשר לך לחפש, להשמיע, לערוך, לארגן ולשתף את התמלילים שלך מכל מקום ובכל מכשיר. מושלם לפגישות, הרצאות, ראיונות, סרטים... כל סוג של אודיו או וידאו, למעשה.

2. אלגוריתמים לזיהוי אדם - על ידי סיסמה:

- **Argon2** : הוא האלגוריתם המתקדם ביותר כיום לאחסון סיסמאות. הוא משתמש בגישה שנקראת Memory Hard, כלומר דורש הרבה זיכרון בעת חישוב Hash, מה שמקשה מאוד על תוקפים להשתמש ב-GPU או בחומרה ייעודית לפיצוח סיסמאות.
- יש לו שלושה גרסאות (Argon2i, Argon2d, Argon2id) המותאמות לסוגי התקפות שונים, ומקובל להשתמש ב-Argon2id.
- **Bcrypt** : הוא אלגוריתם ותיק ואמין מאוד, שנמצא בשימוש נרחב כבר שנים רבות. הוא מוסיף Salt באופן מובנה ומחשב Hash בצורה 'איטית' בכוונה, כדי להאט תקיפות כוח-גס. ניתן לשלוט על רמת הקושי (cost factor), מה שמאפשר להגביר אבטחה ככל שהחומרה מתחזקת.
- **PBKDF2** : אלגוריתם תקין ומוכח, בשימוש נרחב במערכות אבטחה רשמיות. פועל בעזרת חזרות רבות של פונקציית HMAC (בדרך כלל עם SHA-253) בשילוב Salt. אמנם פחות מוגן מפני תקיפות מבוססות חומרה לעומת argon2 ו-bcrypt, אך עדיין נחשב בטוח מאוד ומקובל ביישומים ארגוניים.
- **Scrypt** : אלגוריתם שתוכנן במיוחד כדי להקשות על מתקפות GPU באמצעות צריכת זיכרון גבוהה. בדומה ל-Argon2 גם scrypt הוא Memory Hard, ולכן פיצוח שלו דורש גם זמן וגם משאבי RAM משמעותיים. נחשב חזק ומתאים למערכות הדורשות אבטחה גבוהה מאוד.

3. אלגוריתמים להשוואת טקסט לבדיקת המשכיות שיחה:

- **N-gram Continuation Check** : בודק האם תחילת טקסט B מכילה את אותם רצפים (N מילים) שמסתיימים בטקסט A. שיטה זו מתמקדת ברצף מילים מילולי ולא במשמעות, ולכן טובה במיוחד כשמדובר במשפטים או פסקאות קצרות שבהן המשכיות מילולית ברורה.
- **Semantic Similarity (Embeddings)** : ממיר את כל טקסט למרחב וקטורי שבו כל טקסט מיוצג על ידי משמעותו. לאחר מכן מחשבים דמיון קוסינוס בין הווקטורים. דמיון גבוה מצביע על כך ש-B ממשיך את רעיון או נושא A, גם אם המילים עצמן שונות.
- **Language Model Continuation Probability** : מודל שפה (כמו GPT או BERT) מחשב את ההסתברות שהטקסט B יופיע במשך לטקסט A. אם ההסתברות גבוהה, המשמעות היא שהשפה הטבעית של B מתאימה כתוצאה טבעית מהקשר A.
- **Pattern Continuation / Structural Similarity** : בודק האם B שומר על אותה תבנית או סגנון של A: אורך משפטים, שימוש במילים מסוימות, נושא, זמני פעלים וכו'. דמיון גבוה בין

התכונות המרובות של שני הטקסטים מראה שהמשכיות אפשרית גם אם המילים המדויקות שונות.

- **Levenshtein Distance** : מודד את מספר השינויים (הוספות, מחיקות, החלפות) הדרושים כדי להפוך את סוף A לתחילת B. מרחק קטן מצביע על המשכיות טכנית או מילולית, בעיקר שימושי לטקסטים שבהם המשכיות צריכה להיות כמעט זהה מבחינה מילולית.

שיטת NLP

NLP מחולק ל- 2 מרכיבים עיקריים.

- הבנת שפה טבעית - ייצוג הטקסט בצורה שימושית והבנה מהיבטים שונים.
 - יצירת שפה טבעית - תכנון הטקסט שכולל בחירת מילים ונתינת הטון למשפט.
- SmartService Chat ישתמש בשני חלקים אלו. הבנת השפה טבעית - על מנת להבין את בקשת המשתמש. יצירת שפה טבעית - על מנת ליצור תשובות מובנות למשתמש באופן אישי ככל האפשר.

קשיים:

- עמימות מילונית- מילה עם דו משמעות.
 - עמימות תחבירית- משפט עם דו משמעות.
 - עמימות התייחסותית- דו משמעות כאשר של גוף נסתר.
- לדוגמא: הילדה סיפרה לאימה על החברה שהרביצה לה, היא מאוד כעסה. מי כעסה האמא או הילדה?

מרכיבי NLP

1. ניתוח טקסט ועיבוד מקדים:

- **Tokenization** - כאשר אני מקבלת טקסט אני מנתחת אותו לאסימונים. אסימון יכול להיות חלוקה למשפטים מטקסט ארוך או מילים ממשפט. אני קובעת את החלוקה וכמה מילים יהיו בכל אסימון. טוקניזציה היא תהליך של פירוק טקסט נתון ליחידות הנקראות אסימונים. אסימונים יכולים להיות מילים בודדות, ביטויים או אפילו משפטים שלמים. בתהליך של אסימון, תווים כמו סימני פיסוק עלולים להימחק. האסימונים הופכים בדרך כלל לקלט עבור תהליכים כמו ניתוח וכריית טקסט. פירוק משפט לחלקיו מאפשר למכונה להבין את החלקים כמו את השלם. זה יעזור לתוכנית להבין כל אחת מהמילים בפני עצמה, וגם כיצד הן פועלות, מאוחרים יותר בעיבוד שפה טבעית. הדיוק של האסימון מבוסס על האוצר מילים שהוא מאומן עליו.
- **Stemming** - מציאת מקור המילה - השורש - מציאת השורש ע"י הסרת תחילת וסוף המילה. צריך לשים לב שלא להרוס את המשמעות.
- **Lemmatizat** - הוצאת מילים לא משמעותיות למשפט. מילים לא משמעותיות הן דבר משתנה. בכל ניתוח טקסט יש מילים אחרות שהן לא משמעותיות. תלוי מה מנתחים. יש ניתוחים בהן התארים של הפעלים או שמות העצם יהיו חשובים ואפילו קריטיים לניתוח ולעומת זאת לעיתים המילים החשובות יהיו הפעלים, שמות העצם, או תאורי הזמן - עבר, הווה, עתיד וכו'.
- **Text Normalization**: סטנדרטיזציה של טקסט, כולל נרמול אותיות גדולות וקטנות, הסרת פיסוק ותיקון שגיאות כתיב.
- **tags POS** - מתייג את האסימונים לפעלים שמות עצם וכו'.

2. תחביר וניתוח:

- **Part-of-Speech (POS) Tagging**: הקצאת חלקי דיבר לכל מילה במשפט (למשל, שם עצם, פועל, שם תואר).
- **Dependency Parsing**: ניתוח המבנה הדקדוקי של משפט כדי לזהות קשרים בין מילים.

- **Constituency Parsing**: פירוק משפט לחלקים או לביטויים המרכיבים אותו (למשל, צירופי עצם, צירופי פעלים).
3. ניתוח סמנטי:
- המודל **Named Entity Recognition (NER)**: זיהוי וסיווג ישויות בטקסט, כגון שמות של אנשים וארגונים, מיקומים, תאריכים וכו'.
- המודל **Word Sense Disambiguation (WSD)**: קביעת המשמעות של מילה בה נעשה שימוש בהקשר נתון.
- **Coreference Resolution**: זיהוי מתי מילים שונות מתייחסות לאותה ישות בטקסט (למשל, "הוא" מתייחס ל"יוחנן").
4. חילוף מידע:
- **Entity Extraction**: זיהוי ישויות ספציפיות והקשרים ביניהן בתוך הטקסט.
- **Relation Extraction**: זיהוי וסיווג הקשרים בין ישויות בטקסט.
- 5. סיווג טקסטים ב-NLP:
- **Sentiment Analysis**: קביעת הרגש או הטון הרגשי המובעים בטקסט (למשל, חיובי, שלילי, ניטרלי).
- **Topic Modeling**: זיהוי נושאים או תמות בתוך אוסף גדול של מסמכים.
- **Spam Detection**: סיווג טקסט כספאם או לא ספאם.
- 6. עיבוד דיבור:
- **Speech Recognition**: המרת שפה מדוברת לטקסט.
- **Text-to-Speech (TTS) Synthesis**: המרת טקסט כתוב לשפה מדוברת.
- 7. מענה לשאלות:
- **Retrieval-Based QA**: מציאת והחזרת קטע הטקסט הרלוונטי ביותר בתגובה לשאלתה.
- **Generative QA**: יצירת תשובה המבוססת על המידע הזמין בקורפוס טקסט.
- 8. **מערכות דיאלוג**:
- **Chatbots and Virtual Assistants**: מתן אפשרות למערכות לנהל שיחות עם משתמשים, לספק תגובות ולבצע משימות על סמך קלט המשתמש.
- 9. **ניתוח סנטימנטים ורגשות ב-NLP**:
- **Emotion Detection**: זיהוי וסיווג של רגשות המובעים בטקסט.
- **Opinion Mining**: ניתוח דעות או ביקורות כדי להבין את הסנטימנט הציבורי כלפי מוצרים, שירותים או נושאים.
- 4. אלגוריתמים לניקוי מילות עצירה, סימני פיסוק, רווחים מיותרים, מספרים חסרי משמעות, הטיות מילים:
- **Gensim**: ג'נסים (Generate Similar) היא ספריית תוכנה בקוד פתוח המשתמשת בלמידת מכונה סטטיסטית מודרנית. על פי ויקיפדיה, ג'נסים נועדה לטפל באוספי טקסט גדולים באמצעות הזרמת נתונים ואלגוריתמים מקוונים מצטברים, מה שמבדיל אותה מרוב חבילות התוכנה האחרות בלמידת מכונה המכוונות רק לעיבוד בזיכרון.
- **Scikit-Learn**: בספריית Scikit-Learn, קיימים כלים מובנים לניקוי טקסטים, ובהם תמיכה בסינון מילות עצירה — כלומר מילים שכיחות מאוד שלא מוסיפות משמעות מהותית למשפט (כמו: "של", "על", "עם", "and", "the"). הספרייה כוללת רשימת מילות עצירה מוכנה מראש עבור אנגלית (stop_words='english'), אך מאפשרת גם להזין רשימת מילות עצירה מותאמת אישית.

- **SpaCy** : ספריית spaCy היא אחת מספריות ה-NLP המתקדמות ביותר, והיא כוללת מגוון מובנה וחזק לטיפול במילות עצירה. בניגוד לספריות פשוטות יותר, spaCy לא רק מוחקת מילות עצירה — היא יודעת לזהות אותן כחלק מהעיבוד הלשוני העמוק שהיא מבצעת.
- **NLTK** : היא אחת הספריות הוותיקות והנפוצות ביותר בתחום עיבוד שפה טבעית. היא כוללת מאגר גדול של מילות עצירה עבור שפות רבות, ומספקת כלים פשוטים וגמישים לניקוי טקסטים.
- **TextBlob** : היא ספריית NLP ידידותית וקלה לשימוש, המבוססת על NLTK אך מספקת ממשק פשוט ונוח הרבה יותר. היא מיועדת במיוחד למי שרוצה לבצע משימות עיבוד טקסט בסיסיות בצורה מהירה, בלי להעמיק באלגוריתמים מסובכים.
- **OpenRefine** : הוא כלי קוד פתוח המיועד לניקוי נתונים, סידור מידע מבולגן, איחוד ערכים, והמרת מבנה נתונים. הוא משמש חוקרי נתונים, אנליסטים ומפתחים לעבודות שבהן הנתונים מגיעים מפוזרים, לא אחידים, מלאי שגיאות — וצריך להפוך אותם לנתונים נקיים ומסודרים.

5. חלוקת הטקסט לנושאים:

- **NLTK Sentence Tokenizer** : ערכת הכלים לשפה טבעית (NLTK) מספקת פונקציה שימושית לפיצול טקסט למשפטים. טוקניזטור משפטים זה מחלק גוש טקסט נתון למשפטים המרכיבים אותו, אשר לאחר מכן ניתן להשתמש בהם לעיבוד נוסף.
- **Evaluating Spacy Sentence Splitter** : מפצל המשפטים של Spacy נוטה ליצור קטעים קטנים יותר בהשוואה למפצל טקסט התווים של Langchain, מכיוון שהוא דבק בקפדנות בגבולות המשפט. זה יכול להיות יתרון כאשר יחידות טקסט קטנות יותר נחוצות לניתוח.
- **Adjacent Sequence Clustering** : שיטה זו מייצרת התפלגות מגוונת יותר, דבר המעיד על גישתה התלויה בהקשר. על ידי קיבוץ באשכולות המבוססים על דמיון סמנטי, היא מבטיחה שהתוכן בתוך כל מקטע יהיה קוהרנטי תוך מתן אפשרות לגמישות בגודל המקטע. שיטה זו עשויה להיות יתרון כאשר חשוב לשמר את הרציפות הסמנטית של נתוני טקסט.

6. אלגוריתמים לזיהוי רגשות לצורך זיהוי תלונת לקוח:

- **Naive Bayes** : אלגוריתם זה מסתמך על הסתברות סטטיסטית כדי לקבוע האם טקסט מסוים הוא תלונה. הוא בוחן את תדירות המילים ומחשב את הסיכוי שמשפט שייך לקטגוריה מסוימת על בסיס דוגמאות קודמות. למרות הפשטות שלו, הוא מדויק מאוד במקרים שבהם יש מילים אופייניות שמופיעות לעיתים קרובות בתלונות, ולכן הוא נפוץ מאוד בעיבוד שפה טבעית.
- **Support Vector Machines (SVM)** : אלגוריתם svm מחפש את הגבול הברור ביותר בין טקסטים שהם "תלונה" לבין טקסטים שהם "לא תלונה". הוא מייצג כל טקסט כנקודה מרובת-מאפיינים ובונה קו שמפריד בין הקבוצות בצורה מיטבית. היכולת שלו להתמודד עם נתונים מורכבים וגבולות סיווג לא ליניאריים הופכת אותו לאחד האלגוריתמים המדויקים ביותר בניתוח טקסטים.
- **Logistic Regression** : רגסיה לוגיסטית ממירה טקסט לוקטור מאפיינים, ולאחר מכן מעריכה את ההסתברות שהוא מייצג תלונה. המודל פשוט להבנה, ביצועי, ומספק תוצאות ברורות — האם הטקסט שייך לקבוצת התלונות או לא. הוא יעיל במיוחד במערכות שירות לקוחות שבהן יש צורך בחיזוי דו-ערכי מהיר.
- **Random Forest** : אלגוריתם זה מורכב ממספר רב של "עצים" שכל אחד מהם מנתח את הטקסט מזווית אחרת. כל עץ מבצע סיווג משלו, והמודל משלב את התוצאות של כולם כדי להגיע להחלטה סופית. הגישה הזו עמידה לרעש בטקסט ולסגנונות כתיבה שונים, ולכן היא טובה במיוחד לזיהוי תלונות לא אחידות.
- **CNN To Text** : למרות שפותח במקור עבור תמונות, CNN מצטיין גם בניתוח טקסט באמצעות זיהוי "תבניות" של מילים או צירופי מילים שמאפיינות תלונות. הוא מחליק על הטקסט כמו פילטר ומאתר אזורים חשודים. זהו מודל מהיר ויעיל במיוחד עבור הודעות קצרות או משפטים ברצף.
- **Speech Emotion Recognition (Audio)** : בניתוח תלונות מתוך שמע, אלגוריתם זיהוי רגשות מנתח את טון הדיבור, העוצמה, המהירות והקצב כדי לזהות רגשות כמו תסכול,

כעס או לחץ. גם אם הלקוח לא אומר מילים ברורות של תלונה, שינוי בקולו יכול להצביע על בעיה — והאלגוריתם מזהה זאת.

7. אלגוריתמים לשליפת נתונים ממסד נתונים/מאתרים:
 - **Web Scraping + XPath/CSS Selectors** : זוהי השיטה הקלאסית לשליפת מידע מאתרי אינטרנט: המערכת מורידה את דף ה-HTML ואז משתמשת ב-XPath או CSS Selectors כדי לאתר ולחלץ תגים, טקסטים או מבנים ספציפיים. היתרון הוא דיוק גבוה וקוד יחסית פשוט, אך היא רגישה לשינויים בעיצוב האתר.
 - **API-Based Retrieval** : כאשר אתר מספק API (לרוב JSON/REST), האלגוריתם מבצע שאילתות ישירות לממשק הרשמי ללא צורך בניית HTML. זהו המנגנון המהיר והמדויק ביותר לשליפת מידע ממערכות, ומפחית תקלות בעת שינוי מבנה הדף.
 - **Database extraction or querying** : חילוץ מסד נתונים הוא תהליך של אחזור נתונים ספציפיים ממסד נתונים למטרות כמו ניתוח, דיווח, אינטגרציה או הגירה. זה כרוך בשאילתה על מסד הנתונים כדי לחלץ את המידע הדרוש והמרתו לפורמט מובנה שניתן להשתמש בו על ידי יישומים או מערכות אחרות.
 - **ETL (Extract-Transform-Load) Pipelines** : אלגוריתמי ETL נועדו לשלוף נתונים ממקורות שונים (אתרים, APIs, DBs), לבצע ניקוי/עיבוד ואז לטעון אותם למערכת מרכזית. השיטה מבוססת לרוב על מנועי תזמון (כמו Apache Airflow) ומספקת שליפה רציפה ומבוקרת.
8. אלגוריתמים לניסוח התשובה בצורה אנושית:
 - **Abstractive Summarization – Seq2Seq Models** : אלגוריתמים מבוססי Sequence-to-Sequence עם Attention (כמו LSTM או Transformer) אינם רק מצטטים משפטים קיימים, אלא מנסחים מחדש בצורה ברורה וקצרה. המערכת "מבינה" את ההקשר ובונה ניסוח חדש, מה שהופך אותם לבסיס נפוץ למערכות מענה אוטומטיות.
9. אלגוריתמים הפיכת טקסט לשמע: במקרה שהלקוח על פונקציה שמע.
 - **VITS (Variational Inference TTS)** : מהמודלים המתקדמים ביותר כיום. VITS מייצר את השמע ישירות ללא צורך בשני שלבים (ללא ווקודר נפרד). השיטה מחברת בין Variational Autoencoders, GANs ו-Normalizing Flows ומייצרת קול טבעי מאוד, עם דיקציה מצוינת ואינטונציה אנושית. נחשב ל- "State of the Art".
 - **Concatenative Synthesis Models** : מודלים של Synthesis משולשת מייצגים גישה מסורתית בתחום טכנולוגיית המרת טקסט לדיבור (TTS). מודלים אלה פועלים באמצעות קטעי דיבור מוקלטים מראש שנאספו בקפידה מקולות אנושיים אמיתיים. כל קטע, לרוב פונמה או הברה, מאוחסן במסד נתונים עצום. כאשר מתקבל קלט טקסט, המודל בוחר קטעים מתאימים ומשרשר אותם ליצירת פלט דיבור קוהרנטי.
 - **Parametric Synthesis Models** : מודלים של סינתזה פרמטרית מציעים גישה רבת-תכלית לטכנולוגיית טקסט לדיבור. הם יוצרים דיבור על סמך פרמטרים פונטיים במקום להסתמך על קטעי קול מוקלטים מראש. מודלים אלה ממירים טקסט לייצוגים פונטיים ולאחר מכן מסנתזים דיבור באמצעות פרמטרים כמו גובה צליל, משך זמן ואינטונציה.
 - **Neural Network-Based Models** : מודלים מבוססי רשתות עצביות משתמשים בשיטות סטטיסטיות ולמידת מכונה כדי לייצר דיבור. הם ממנפים אוספים נרחבים של דגימות דיבור כדי ללמד רשתות עצביות כיצד לייצר דיבור המחקר אינטונציות ומקצבים אנושיים.
 - **Murf Falcon** : מתוכנן לספק דיבור דמוי אדם עם זמן השהייה מוביל בתעשייה של 55 מילישניות ברחבי העולם. השתמשו ב-Falcon כדי לפרוס סוכני קול מבוססי בינה מלאכותית

שלא רק מדברים כמו בני אדם רגילים, אלא גם מספקים את הדיבור במהירות מסחררת ובדיוק אולטרה-מדויק. Falcon הוא ממשק ה-TTS היחיד ששומר באופן עקבי על זמן השמע הראשון מתחת ל-130 מילישניות על פני 10+ אזורים גלובליים, אפילו בעת עיבוד של עד 10,000 שיחות בו זמנית. Falcon מספק דיבור טבעי ללא הפרעות. ללא השהייה, ללא ביטויים מקוטעים, ללא צליל רובוטי.

מודלים שנבחרו

- **BERTopic - עבור מציאת נושא מתוך טקסט.**
BERTopic חזק בזיהוי נושאים סמנטיים מתוך טקסט חופשי. הוא מאפשר למערכת להבין במהירות את ההקשר של השיחה, גם כשמדובר בטקסטים מורכבים או מגוונים, ולספק ניתוח משמעותי של תוכן המשתמש.
- **S-BERT - להשוואה בין טקסטים.**
S-BERT מצטיין במדידת דמיון סמנטי בין טקסטים. היתרון שלו הוא הדיוק בהשוואה בין נושאים שונים, מה שמאפשר למנוע כפילויות ולארגן את המידע בצורה עקבית וממוקדת.
- **DistilBERT fine-tuned - להבנת משמעות הטקסט.**
DistilBERT מהיר וקל, ובזכות ה-fine-tuning הוא מבין היטב את הכוונה של המשתמש. היתרון שלו הוא יכולת זיהוי כוונה גם בטקסטים קצרים או לא פורמליים, מה שמגביר את הדיוק במענה לצרכי המשתמש.
- **T5/BART - ליצירת שאלות ממוקדות על פרטים חסרים.**
T5 ו-BART מצטיינים ביכולת לייצר טקסטים בצורה טבעית וחכמה. היתרון הוא שהם מאפשרים למערכת לשאול את השאלות הנכונות בדיוק ובאופן שהלקוח ירגיש טבעי ומעורב בשיחה, בלי להיראות מכני.
- **DistilBERT fine-tuned - זיהוי תלונה מתוך טקסט.**
מודל זה חזק בסיווג טקסטים ומסוגל לזהות מתי מדובר בתלונה. היתרון הוא שהמערכת יכולה להתמקד רק במידע הרלוונטי, ולא להתבלבל בין הערות, בקשות או תלונות, מה שמייעל את התגובה.
- **MFCC → BiLSTM - זיהוי רגש תלונה מתוך שמע.**
שילוב זה מאפשר לזהות רגשות מתוך הקול של המשתמש. היתרון הוא שהוא מתרגם אינטונציה, טון ועוצמת דיבור למידע אמיתי על רגשות, וכך מאפשר הבנה עמוקה יותר של חומרת התלונה.
- **BART - סיכום התלונה.**
המודל BART מצטיין ביצירת סיכומים ברורים וטבעיים. היתרון הוא שהמערכת יכולה להבין במהירות את עיקרי התלונה בלי לפספס פרטים חשובים, תוך שמירה על ניסוח קולח ואנושי.
- **DistilBERT fine-tuned - מציאת סיבת התלונה.**
DistilBERT כאן מספק דיוק בזיהוי הגורם העיקרי לתלונה. היתרון הוא שהוא מסנן מידע לא רלוונטי ומספק ניתוח ממוקד שמוביל לפתרון יעיל.
- **T5/BART fine-tuned - יצירת פיצוי או פתרון לבעיה.**
T5 ו-BART מאפשרים ניסוח פתרונות מותאמים אישית. היתרון הוא שהמערכת יכולה להציע מענה מקצועי, ברור ונעים ללקוח, שכולל פיצוי או פתרון שמרגיש טבעי ואנושי.
- **מודל (LLM) GPT - שליפת הנתונים**
GPT מצטיין בגמישות וביכולת להתמודד עם שאלות חופשיות. היתרון הוא שהמערכת יכולה לשלוף מידע רלוונטי גם כשבקשת המשתמש מורכבת או לא מדויקת, מבלי לאבד דיוק.
- **המודל S-BERT - לבחירת התשובה המתאימה ביותר.**

מודל זה מאפשר מדידה מדויקת של דמיון בין בקשת המשתמש לאפשרויות התשובה. היתרון הוא הבחירה המדויקת ביותר עבור כל מקרה, מה שמעלה את איכות התשובה הסופית ומפחית טעויות.

- **המודל BART - ניסוח התשובה למשתמש בצורה טבעית.**
- BART מצטיין ביצירת ניסוח קולח, מקצועי וטבעי. היתרון הוא שהתשובות שמתקבלות מרגישות אנושיות, נוחות לקריאה ומקצועיות, מה שמגביר את חוויית המשתמש.

הליכים עיקריים בפתרון בעיה בטכנולוגיות הנדסה מתקדמות

- זיהוי משתמש על ידי הזנת קוד.
- בדיקה על פי השאלה האם שיחה זו שיחת המשך.
- קבלת שמע או טקסט מהמשתמש המכיל את הבקשה.
- ניתוח הבקשה.
- חיפוש ובחירת תשובה ממסדי נתונים או אתרי אינטרנט.
- ניסוח התשובה בצורה אנושית.
- החזרת התשובה למשתמש. שמע או טקסט על פי צד המשתמש.
- בסיום השיחה שמירת סיכום השיחה.

הליכים עיקריים בלמידת מכונה

1. למידת מכונה עבור המרת אודיו לטקסט :

נתונים ל-Dataset:

- הקלטות קול של אנשים שונים.
- תמלול מדויק לכל הקלטה.
- מגוון סגנונות דיבור, מבטאים ומהירויות.
- הקלטות עם וריאציות של רעשי רקע.

מודלים מתאימים:

- מודלים אקוסטיים+ מודלי שפה, לדוגמא: CNN + RNN* .
- מודלי Sequence-to-Sequence .
- *מודלים מודרניים כמו Wav2Vec2, Whisper .
- המודל לומד לקשר בין מאפייני קול, תווים/ מילים.

אימון:

- המודל לומד לקשר בין מאפייני קול, תווים/ מילים.
- שילוב של מודל אקוסטי ומודל שפה לדיוק גבוה.

מדדי הצלחה:

- WER – Word Error Rate (כמה מילים שגויות).
- CER – Character Error Rate .
- השוואת רמת שגיאות התמלול בין סוגים שונים של קטעי דיבור.

2. למידת מכונה עבור ניתוח טקסט:

נתונים ל-Dataset:

- משפטים וטקסטים עם תיוגים, כגון: רגש: חיובי/ שלילי/ ניטרלי. סיווג כוונה: שאלה, טענה, בקשה. ונושאים (Topic Classification).

מודלים מתאימים:

- Bag-of-Words/TF-IDF + SVM/Logistic Regression
- המודל Word Embeddings (Word2Vec / GloVe + LSTM)
- מודלים מתקדמים: BERT או RoBERTa

אימון:

- הכנסת טקסט כווקטורים.
- המודל לומד לזהות רגש, כוונה וסגנון.

מדדי הצלחה:

- דיוק.
- Precision / Recall / F1-score
- בלבול בין רגשות.

3. למידת מכונה עבור זיהוי רגשות:

נתונים ל-Dataset:

- משפטים משיחות אמיתיות.
- תיוג רגשות: כעס, בלבול, שביעות רצון, תלונה, נייטרלי וכו'.
- אם נדרש: גם מאפיינים קוליים (pitch, energy).

מודלים מתאימים:

- Text Emotion Classifiers: BERT Emotion, RoBERTa, DistilBERT
- Audio Emotion Recognition (SER): CNN + LSTM, wav2vec2 finetuned

אימון:

- שילוב טקסט + פרמטרים קוליים (מודל מולטי-מודלי).
- Fine-tuning על דוגמאות של לקוחות אמיתיים.
- לימוד דפוסים המעידים על תלונה/כעס/תסכול.

מדדי הצלחה:

- F1 Score לכל רגש.
- Emotion Confusion Matrix

4. למידת מכונה עבור הפיכת טקסט לשמע:

נתונים ל-Dataset:

- זוגות טקסט-שמע.
- מאגרי דיבור נקיים: משפט → קובץ קול.

- אפשר לגוון דוברים, טונים וקצבים (אם צריך).

מודלים מתאימים:

- Tacotron 2 – ליצירת ספקטרוגרמה.
- FastSpeech / FastSpeech2 – דגמים מהירים יותר.
- WaveGlow / HiFi-GAN – ווקודרים להמרת ספקטרוגרמה לשמע.

אימון:

- שלב 1: אימון Tacotron/FastSpeech על זוגות טקסט-מל-ספקטרוגרמה.
- שלב 2: אימון ווקודר להמרת ספקטרוגרמה לשמע אמיתי.
- Fine-tuning על דגימות שלך לשמירה על סגנון דיבור עקבי.

מדדי הצלחה:

- MOS (Mean Opinion Score): דירוג אנושי על איכות הקול.
- טבעיות (Naturalness).
- הבהירות (Intelligibility).
- זמן ריצה ליצירת שמע.

הליכים עיקריים בתחום מערכות הפעלה/רשתות מחשבים/תקשורת

נתונים/אבטחת מידע

ארכיטקטורות המערכת (לקוח-שרת):

- צד לקוח: דפדפן בו המועמד והחברה משתמשים בממשק אינטרנטי (טופס הגדרות לחברה, מסך ריאיון למועמד).
- צד שרת: שרת יישומים שמקבל בקשות מהלקוח, מעבד את האודיו והטקסט, ומחזיר תוצאות ודו"חות.
- מסד נתונים: שרת בסיס נתונים שבו נשמרים נתוני משתמשים, שאלות, תמלולים ותוצאות ניתוח.

התקני קלט/פלט:

- מחשב.
- עכבר.
- מקלדת.
- מיקרופון.
- רמקול.

תהליכי תקשורת בין לקוח לשרת:

- שליחת בקשת התחברות מהלקוח לשרת לצורך זיהוי ואימות.
- קבלת שאלה מהשרת עבור הבוט.
- שליחת קובץ שמע/טקסט של שאלת המשתמש לשרת.
- העברת תוצאות העיבוד מהשרת ללקוח.
- שליחת בקשה לקבלת דו"ח מסכם.
- החזרת דו"ח מסכם מהשרת ללקוח.

אבטחת מידע:

- הצפנת תקשורת בין הלקוח לשרת.
- שמירת נתונים רגישים (שאלות, תמלולים) במסד הנתונים בצורה מאובטחת ומוגנת.

- הגבלת גישה לפי תפקיד: משתמש רגיל רואה רק את הנתונים והיסטורית שיחות שלו, מנהל רואה את כל היסטוריות השיחות וכן את סיכומי השיחות.
- אימות משתמשים בעת כניסה למערכת כדי למנוע גישה של גורם לא מורשה.

תיאור פרוטוקולי תקשורת

פרוטוקול HTTPS.

פיתוחים עתידיים

- **הרחבת יכולות הניתוח:** שילוב רכיבים מתקדמים לניתוח עומק של תשובות, כמו זיהוי דקויות ניסוח ומורכבות חשיבה. המערכת תוכל להציע קטגוריות עומק נוספות ולהבין סוגי הבעה שונים בצורה מדויקת יותר.
- **הרחבה יכולות שפתיות:** הרחבת תמיכה לשפות נוספות כמו אנגלית וערבית על מנת להנגיש את הכלי ליותר אנשים.
- **שרות פרואקטיבי:** הצאת מנתח את אופן פעולות המשתמש וחזרה פעולות נוספות ומקפיץ הודעה למשתמש על כך.
- **אינטגרציה רב-ערוצית:** הצאת יכול לסנכרן נתונים בין אפשרויות שימוש שונות. כלומר המשתמש יכול להשתמש בשירותי הצאת באותה עת גם מהמייל וגם מהשיחה קולית.

תיאור טכנולוגיה הנדסה

צד שרת - Python , C#.

צד לקוח - react.

בצד שרת נבדקו החלופה הבאה: C++.

C++ היא שפה "קרובה לחומרה", שנותנת למתכנת שליטה ידנית מלאה על הזיכרון ומציעה ביצועים מקסימליים. היא משמשת למערכות קריטיות כגון מנועי משחקים ומערכות הפעלה.

C# היא שפה "ברמה גבוהה", מודרנית, ומופעלת על ידי סביבת .NET. היא מנהלת את הזיכרון באופן אוטומטי, מה שהופך אותה לקלה יותר לתכנות. היא אידיאלית לפיתוח יישומי ווב ואפליקציות.

Python שפת תכנות ברמה גבוהה, קלה ונוחה לשימוש, שפה דינמית, שפה מפורשת מה שמקל על איתור באגים היתרון הבולט שלה זה התמיכה הרחבה בספריות שיכולות לעזור בעת כתיבת הפרויקט-מתאימה ללמידת מכונה.

בצד לקוח נבדקו החלופה הבאה: Angular .

React - מספקת פתרון חלקי הכולל רק ספרייה, יש לעדכן את הקוד לעיתים קרובות לפי העדכונים של הספרייה.

Angular - מספקת פתרון מלא, יש לה מלא ספריות דבר שיכול לחסוך את תהליך התכנון.

פרטים פורמליים

מסד נתונים:

הפרויקט נעזר במסד נתונים Sql לשמירת משתמשים ודוחות שיחה.

לוחות זמנים:

נובמבר: חקירה מעמיקה על הנושאים.
דצמבר: המשך החקירה והתחלת הכתיבה.
ינואר: כתיבת צד שרת ואימון המודלים.
פברואר-מרץ: סיום צד שרת ומעבר לצד לקוח.

אפריל: חיבור בין צד שרת ללקוח.
מאי: שיפור ושיוף של המערכת.

מנחות הפרויקט: ת.ס.ט

חתימת הסטודנט: תמר מוריאל

חתימת רכזת המגמה: א.ג.ל